

AgroIA

Julián H. Arana V.

David F. Lopez M.

Aplicación de la inteligencia artificial, Ingeniería de Sistemas,
Universidad Cooperativa de Colombia, Campus Villavicencio

Mgtr. Yomaria Guzman Paredes

Villavicencio

21 de noviembre de 2025

Tabla de contenido

1.	Introducción.....	4
1.1	Resumen	4
1.2	Abstract.....	4
2.	Planteamiento del problema	6
2.1	Justificación	6
3.	Objetivos.....	8
3.1	Objetivo general	8
3.2	Objetivos específicos	8
3.3	Descripción de la propuesta.....	8
4.	Marco referencial.....	10
4.1	Estado del arte	10
4.2	Marco teórico.....	10
4.3	Marco Legal.....	11
5.	Metodología.....	14
5.1	Sprint:	15
5.2	Historias de Usuario - Proyecto AgroIA.....	16
5.3	Metodología de la inteligencia artificial (Enfoque CRISP-DMpara AgroIA)	18
6.	Modelado	21
7.	Resultados.....	23
8.	Ánálisis y discusión.....	29
9.	Conclusiones.....	30
10.	Referencias	31

Tabla de figuras

Figura 1	15
Figura 2	16
Figura 3	21
Figura 4	23
Figura 5	24
Figura 6	24
Figura 7	26
Figura 8	27
Figura 9	28

1. Introducción

El cultivo de plátano es una de las actividades agrícolas más relevantes en las regiones tropicales, no solo como fuente de alimento, sino también como sustento económico para muchas familias campesinas. En el departamento del Meta, Colombia, esta producción tiene un papel destacado en la seguridad alimentaria y el desarrollo rural. Sin embargo, los platanales enfrentan amenazas constantes por enfermedades como la Sigatoka negra, la Fusariosis (Mal de Panamá), el Moko bacteriano y el Virus del mosaico, que afectan las hojas, raíces, pseudotallo y frutos, ocasionando pérdidas significativas en la calidad y cantidad de la cosecha.

Tradicionalmente, la detección de estas enfermedades depende de la observación visual realizada por agricultores o técnicos, un proceso que puede ser tardío, subjetivo y costoso. Frente a esta problemática, la inteligencia artificial se presenta como una herramienta innovadora para el reconocimiento temprano de síntomas en las plantas mediante el análisis automatizado de imágenes. En este contexto, surge AgroIA un proyecto que aplica redes neuronales convolucionales para identificar y clasificar de manera automática las principales enfermedades del plátano a partir de fotografías. Su propósito es apoyar la toma de decisiones agrícolas en el Meta, reducir pérdidas productivas y promover un manejo más eficiente y sostenible de los cultivos en la región.

1.1 Resumen

La agricultura enfrenta desafíos significativos debido a la propagación de diversas enfermedades que afectan la productividad y calidad de los cultivos. La detección temprana y precisa de estas afecciones resulta esencial para reducir perdidas y optimizar los procesos agrícolas, pero los métodos tradicionales basados en la observación visual suelen ser lentos, subjetivos y dependientes de la experiencia del operador. En este contexto, el proyecto AgroIA propone el desarrollo de una herramienta basada en inteligencia artificial que emplea redes neuronales convolucionales (CNN) para analizar imágenes de plantas y reconocer síntomas de enfermedades en diferentes etapas.

1.2 Abstract

Agriculture faces significant challenges due to the spread of various diseases that

affect crop productivity and quality. Early and accurate detection of these diseases is essential to reduce losses and optimize agricultural processes; however, traditional methods based on visual observation are often slow, subjective, and dependent on the operator's experience. In this context, the AgroIA project proposes the development of an artificial intelligence-based tool that employs Convolutional Neural Networks (CNNs) to analyze plant images and identify disease symptoms at different stages.

2. Planteamiento del problema

Descripción del problema El cultivo de plantas y árboles constituye una actividad agrícola y ambiental de gran relevancia, tanto por su aporte a la seguridad alimentaria como por su papel en la economía y sostenibilidad de los ecosistemas rurales. Sin embargo, la productividad y salud de estas especies se ven amenazadas por diversas enfermedades de origen fúngico, bacteriano y viral, que afectan hojas, raíces, tallos y frutos, reduciendo su crecimiento, capacidad fotosintética y rendimiento general. La detección temprana de estas afecciones representa un reto, ya que los métodos tradicionales se basan principalmente en la observación visual realizada por agricultores o técnicos, un proceso que resulta subjetivo, tardío y dependiente de la experiencia del observador. Además, en muchas zonas rurales persisten limitaciones en el acceso a tecnologías de diagnóstico y monitoreo continuo, lo que incrementa el riesgo de pérdidas económicas y ecológicas. Frente a este panorama, surge AgroIA, un sistema inteligente orientado a la identificación automática de enfermedades del plátano, como Sigatoka negra, Cordana, Pestalotiopsis y el reconocimiento de plantas sanas. Mediante el análisis de imágenes. Para su desarrollo, se implementará la metodología ágil Scrum, que permitirá gestionar de forma iterativa e incremental los requerimientos del sistema, garantizando una comunicación constante entre los roles del equipo, una rápida adaptación a los cambios y la entrega continua de valor funcional. De esta manera, se busca fortalecer el control sanitario de los cultivos, optimizar los procesos de diagnóstico y contribuir a la sostenibilidad y eficiencia de la producción agrícola.

2.1 Justificación

El desarrollo de AgroIA surge como respuesta a la necesidad de optimizar los procesos de diagnóstico y monitoreo de enfermedades en cultivos de plátano, una de las actividades agrícolas más representativas del país. Tradicionalmente, la detección de afecciones como Sigatoka negra, Cordana y Pestalotiopsis depende de la observación visual del agricultor o técnico, lo cual implica limitaciones en precisión, rapidez y disponibilidad de recursos tecnológicos en zonas rurales.

Ante esta problemática, AgroIA propone un enfoque innovador basado en inteligencia artificial y visión por computadora, capaz de identificar de manera automática

y confiable el estado sanitario de las plantas a partir del análisis de imágenes. Esta herramienta contribuye a mejorar la productividad agrícola, reducir las pérdidas económicas y promover una gestión sostenible de los cultivos mediante la detección temprana de enfermedades. El proyecto se desarrolla bajo la metodología ágil Scrum, lo que permite una gestión flexible, colaborativa y orientada a resultados. A través de la planificación en sprints, la definición de roles y la entrega continua de incrementos funcionales, se asegura la calidad del producto y la adaptabilidad frente a los cambios en los requerimientos. En conjunto, AgroIA no solo tiene un impacto tecnológico, sino también social y económico, al ofrecer una solución accesible que fortalece la competitividad del sector agrícola y fomenta la adopción de herramientas inteligentes en el contexto de la transformación digital rural.

3. Objetivos

3.1 Objetivo general

Desarrollar una herramienta tecnológica basada en inteligencia artificial y arquitectura por capas que permita la detección y clasificación de plantas mediante el análisis automatizado de imágenes, facilitando la gestión sanitaria y el control de inventarios en entornos agrícolas y forestales.

3.2 Objetivos específicos

- Aplicar la arquitectura por capas para estructurar el sistema en módulos independientes, tales como la gestión de imágenes, el procesamiento del modelo de IA, el almacenamiento de resultados y la visualización.
- Validar la efectividad del modelo mediante pruebas con imágenes nuevas y analizar su potencial aplicación en sistemas de apoyo a la toma de decisiones agrícolas.
- Integrar las diferentes capas en una plataforma central que facilite la comunicación entre componentes, optimizando el rendimiento y permitiendo futuras ampliaciones funcionales.

3.3 Descripción de la propuesta

El proyecto AgroIA propone el desarrollo de una herramienta tecnológica basada en inteligencia artificial, orientada a la identificación y clasificación automática de las principales enfermedades del plátano mediante el análisis de imágenes digitales. Para ello, se implementará una red neuronal convolucional (CNN) entrenar con un conjunto de datos compuesto por fotografías de hojas de plátano que representan cuatro categorías: Sigatoka negra, Cordana, Pestalotiopsis y planta sana.

El sistema estará diseñado para reconocer patrones visuales característicos en las hojas, como manchas, decoloraciones y texturas, permitiendo distinguir entre plantas sanas y afectadas con un alto grado de precisión. Este enfoque representa una alternativa innovadora frente a los métodos tradicionales de diagnóstico agrícola, que suelen ser tardíos, subjetivos y dependientes de la experiencia del observador. Asimismo, AgroIA se desarrolla bajo la metodología ágil Scrum, lo que permite una gestión iterativa e incremental del proyecto. A través de la definición de roles, la planificación por sprints y la entrega continua de funcionalidades, se busca asegurar la calidad del producto, la

colaboración del equipo y la adaptabilidad ante nuevos requerimientos. A futuro, la propuesta podrá evolucionar hacia una aplicación web o móvil, permitiendo a los agricultores del departamento del Meta acceder fácilmente al sistema para diagnosticar el estado sanitario de sus cultivos. De esta manera, AgroIA contribuirá a la detección temprana de enfermedades, la reducción de pérdidas productivas y la promoción de una agricultura más eficiente, sostenible e impulsada por la tecnología.

4. Marco referencial

4.1 Estado del arte

Detección de Sigatoka Negra mediante CNN (Trabajo de grado 2024, Universidad de los Llanos) Este trabajo desarrolla una red neuronal convolucional (CNN) entrenada con imágenes de hojas de plátano sanas y afectadas por Sigatoka negra. Se logró una precisión superior al 90% en la clasificación de imágenes, evidenciando el potencial de las CNN para el reconocimiento de patrones visuales en hojas infectadas.

Clasificación de enfermedades en plátano usando aprendizaje profundo (Trabajo de grado 2023, Universidad Nacional) La investigación implementó un modelo de CNN combinado con técnicas de procesamiento de imágenes, como aumento de datos y normalización de color, para diferenciar entre Fusariosis, Moko bacteriano y hojas sanas. El modelo alcanzó una alta sensibilidad y especificidad, destacando la relevancia de los algoritmos de aprendizaje profundo en el análisis de enfermedades foliares.

Sistema de apoyo al agricultor mediante IA y visión por computador (Trabajo de grado 2022, Universidad del Meta) Este proyecto desarrolló una herramienta de diagnóstico que utiliza procesamiento de imágenes para segmentar las áreas afectadas de las hojas y clasificarlas según el tipo de enfermedad. El sistema permitió a los agricultores obtener un diagnóstico rápido y confiable sin necesidad de intervención de expertos, evidenciando el impacto práctico de la IA en el sector agrícola.

4.2 Marco teórico

Inteligencia Artificial en Agricultura La Inteligencia Artificial (IA) es un área de la informática que busca desarrollar sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el aprendizaje, la percepción y la toma de decisiones (Russell & Norvig, 2021). En agricultura, la IA se aplica para optimizar la producción, monitorear cultivos y detectar enfermedades de manera automática y precisa. Los sistemas de IA reducen la dependencia del conocimiento experto y permiten decisiones más rápidas y eficientes.

Visión por Computador y Procesamiento de Imágenes La visión por computador permite a las máquinas interpretar y analizar imágenes digitales. En el contexto agrícola, se

utiliza para identificar patrones visuales en hojas y frutos, como manchas, decoloraciones o deformaciones causadas por enfermedades. El procesamiento de imágenes incluye técnicas como:

- Segmentación: separar la hoja del fondo o las áreas afectadas del tejido sano.
- Aumento de datos: generar variaciones de las imágenes para mejorar el entrenamiento del modelo.
- Normalización de color y reducción de ruido: para estandarizar las imágenes y facilitar la detección de patrones relevantes.

Redes Neuronales Convolucionales (CNN) Las CNN son un tipo de red neuronal especialmente diseñada para analizar imágenes. Están formadas por capas de convolución, activación, *pooling* y *fully connected*, que permiten extraer características visuales de bajo y alto nivel, como bordes, texturas y formas complejas. En el análisis de hojas de plátano, las CNN son capaces de diferenciar entre hojas sanas y aquellas afectadas por enfermedades como Sigatoka negra, Pestalotiopsis etc.

4.3 Marco Legal

El desarrollo del proyecto AgroIA, que combina inteligencia artificial con el diagnóstico fitosanitario mediante imágenes, se enmarca en diversas normas nacionales e internacionales que regulan el uso de la información, los datos personales, la propiedad intelectual y las tecnologías aplicadas a la agricultura.

Ley 1581 de 2012 – Protección de Datos Personales

La Ley 1581 de 2012 establece las disposiciones generales para la protección de datos personales en Colombia, reconociendo el derecho de todas las personas a conocer, actualizar y rectificar la información recopilada sobre ellas (Congreso de la República de Colombia, 2012).

En el caso de AgroIA, esta norma es aplicable porque el sistema podría recopilar datos personales de productores agrícolas o georreferencias de sus fincas, por lo cual es obligatorio garantizar su confidencialidad y uso exclusivo para fines académicos y de diagnóstico agrícola.

Asimismo, el Decreto 1377 de 2013 reglamenta parcialmente la ley y exige el

consentimiento informado para el uso de información personal y visual (Presidencia de la República de Colombia, 2013).

Ley 1266 de 2008 – Habeas Data Financiero y de Información

Aunque esta ley se centra en el ámbito financiero, sienta un precedente sobre el tratamiento responsable de bases de datos en Colombia, exigiendo medidas de seguridad, acceso restringido y finalidad legítima de la información almacenada (Congreso de la República de Colombia, 2008).

AgroIA debe aplicar principios similares para el manejo de su base de datos Oracle, asegurando que los datos almacenados (imágenes, coordenadas, resultados de predicciones) sean utilizados solo con fines investigativos y no comerciales.

Ley 23 de 1982 y Decisión Andina 351 de 1993 – Derechos de Autor y Propiedad Intelectual

El contenido visual capturado o generado en el proyecto (fotografías, dataset, interfaz, modelo de IA) se considera una obra protegida por derechos de autor según la Ley 23 de 1982 (Congreso de la República de Colombia, 1982) y la Decisión Andina 351 de 1993 de la Comunidad Andina (CAN, 1993).

Por lo tanto, se reconoce la autoría de los estudiantes y docentes que desarrollen AgroIA, garantizando que el material solo pueda usarse bajo fines académicos, citando a sus creadores.

Ley 1341 de 2009 – Sociedad de la Información y Tecnologías TIC

La Ley 1341 de 2009 fomenta el uso de las tecnologías de la información y las comunicaciones (TIC) como herramientas para la innovación y el desarrollo (Congreso de la República de Colombia, 2009).

Este marco jurídico legitima el uso de la inteligencia artificial en sectores productivos, como la agricultura, en la medida en que promueve la transformación digital del campo colombiano, coherente con los objetivos del Ministerio TIC y los programas de Agricultura 4.0.

Ley 1955 de 2019 – Plan Nacional de Desarrollo 2018–2022

El artículo 142 de esta ley impulsa la transformación digital y la adopción de inteligencia artificial como ejes del desarrollo sostenible (Congreso de la República de Colombia, 2019).

AgroIA se alinea con esta política pública al proponer una solución tecnológica que mejora la competitividad rural, optimiza la detección de enfermedades agrícolas y contribuye a la seguridad alimentaria.

Ley 99 de 1993 – Medio Ambiente y Desarrollo Sostenible

Esta norma crea el Ministerio de Ambiente y regula la gestión ambiental del país. El uso de herramientas tecnológicas como AgroIA puede apoyar la agricultura sostenible, al reducir el uso excesivo de agroquímicos mediante diagnósticos tempranos y precisos (Congreso de la República de Colombia, 1993).

Decreto 2369 de 2019 – Política Nacional de Inteligencia Artificial

El Decreto 2369 de 2019 establece la Política Nacional de Inteligencia Artificial de Colombia, cuyo objetivo es promover el desarrollo y la adopción ética, responsable y confiable de la IA (Presidencia de la República de Colombia, 2019).

AgroIA se inscribe en este marco al aplicar IA en beneficio social y ambiental, fomentando el aprendizaje automático con datos abiertos y respetando los principios de ética algorítmica y transparencia.

Normas internacionales aplicables

Reglamento General de Protección de Datos (GDPR) de la Unión Europea (2016), que define buenas prácticas globales para el tratamiento de datos personales y biométricos.

Diretrices de la FAO sobre Agricultura Digital (2022), que promueven el uso responsable de tecnologías emergentes en el sector agropecuario, priorizando la sostenibilidad, privacidad y equidad (FAO, 2022).

5. Metodología

Metodología ingenieril La investigación desarrollada en AgroIA es de tipo aplicada, cuantitativa y experimental, orientada al diseño de un sistema de inteligencia artificial capaz de identificar enfermedades en hojas de plátano mediante análisis de imágenes. Para la gestión del proyecto se adopta la metodología ágil Scrum, la cual permite organizar el trabajo en ciclos iterativos o sprints, facilitando la colaboración constante del equipo, la retroalimentación continua y la adaptación a cambios durante el desarrollo. En este contexto, el Product Owner define los requisitos del sistema y prioriza las funcionalidades, el Scrum Master facilita la comunicación y supervisa la correcta implementación de Scrum, mientras que el equipo de desarrollo implementa el modelo de IA, realiza pruebas y ajusta el sistema según los resultados obtenidos en cada sprint.

AgroIA se estructura siguiendo una arquitectura por capas, lo que permite organizar el sistema en módulos independientes y escalables. La capa de presentación corresponde a la interfaz de usuario, donde se cargan las imágenes de hojas de plátano y se visualizan los resultados de la clasificación. La capa de lógica de negocio se encarga de procesar las imágenes, aplicar preprocesamiento y ejecutar el modelo de inteligencia artificial. La capa de datos almacena las imágenes, etiquetas de enfermedades y resultados de predicción, mientras que la capa de integración gestiona la comunicación entre la base de datos, la lógica de negocio y la interfaz de usuario.

La creación y procesamiento del dataset es un componente fundamental del proyecto. Se recolectan imágenes de hojas sanas y afectadas por Sigatoka negra, Cordana y Pestalotiopsis, provenientes de cultivos locales y bases de datos públicas. Cada imagen es etiquetada según su enfermedad o estado sano. Posteriormente, se realiza un preprocesamiento que incluye la normalización de color, la segmentación de hojas y el aumento de datos mediante técnicas como rotación, escalado y cambios de iluminación, con el fin de mejorar la generalización del modelo.

El desarrollo del proyecto AgroIA se basó en el marco de trabajo ágil Scrum, el cual permitió organizar las actividades en sprints cortos e iterativos, fomentando la colaboración, la flexibilidad y la mejora continua del producto.

El equipo de trabajo se conformó con los siguientes roles:

- Product Owner: Julian Arana, encargado de definir los requerimientos, priorizar las

funcionalidades y garantizar que el sistema cumpla con las necesidades del usuario final.

- Scrum Master: David López, responsable de asegurar el cumplimiento del marco de trabajo Scrum, facilitar la comunicación y eliminar los impedimentos que pudieran afectar el desarrollo.
- Equipo de desarrollo: Integrado por ambos participantes, responsables del diseño de la arquitectura por capas, el desarrollo de la red neuronal convolucional (CNN), la implementación del backend y la creación de la interfaz con Gradio.

El proceso de desarrollo se dividió en tres fases principales:

Planificación del producto: Se definieron los objetivos, el alcance y los requerimientos funcionales de AgroIA, orientados a la detección de enfermedades del plátano como Sigatoka negra, Cordana, Pestalotiopsis y la identificación de plantas sanas.

Desarrollo iterativo: Cada sprint se enfocó en la implementación de módulos dentro de la arquitectura por capas:

- Capa de presentación: Interfaz creada con Gradio.
- Capa de lógica de negocio: Implementada con Python
- Capa de inteligencia artificial: Entrenamiento del modelo CNN con TensorFlow y preprocesamiento de imágenes con OpenCV/PIL.
- Capa de datos: Administración de información mediante PostgreSQL.

Pruebas y mejora continua: Se realizaron pruebas de rendimiento del modelo y validación del sistema con imágenes reales, ajustando los parámetros de la CNN para optimizar la precisión y confiabilidad del diagnóstico.

5.1 Sprint:

Figura 1

Sprint del proyecto AgroIA realizados en clickUp

The screenshot shows a ClickUp workspace titled "Julian Arana's Workspace". The main view is a Kanban board with three columns: "PENDIENTE" (7 tasks), "EN CURSO" (5 tasks), and "COMPLETADO" (1 task). The "PENDIENTE" column has three sub-tasks: "Tarea 2" (due Oct 19, priority Alta), "Tarea 3" (due Oct 27, priority Alta), and another "Tarea 2" (due Nov 4, priority Alta). The "EN CURSO" column contains tasks like "Design a Workflow That Works for You" and "Diseñar la arquitectura base de la red neuronal". The "COMPLETADO" column contains a single task: "Preparar informe técnico y presentación". The sidebar on the left includes links for Inicio, Agenda, Brain, Equipo, Documentos, Mis, Invitar, and Suscribirse.

Figura 2

Tareas que se incorporaron a los Sprint

Atrasado		13	...	+
Nombre		Prioridad	Fecha límite	
Bring Your Team Onboard in Minutes		Alta	11/14/25	
Integrate Your Favorite Tools in ClickUp		Alta	11/2/25	
Work Smarter with ClickUp AI		Alta	10/31/25	
Cierre y retrospectiva del proyecto		Alta	10/17/25	
Validar el modelo y documentar errores		Alta	10/15/25	
Diseñar la arquitectura base de la red neuronal		Alta	10/13/25	
Entrenar el modelo base y ajustar hiperparámetros		Alta	10/9/25	
Definir el alcance del proyecto y objetivo principal		Alta	10/7/25	
Implementar mejoras y comparar arquitecturas		Alta	10/5/25	
Preprocesar imágenes y dividir dataset		Alta	10/3/25	
Recolectar y organizar el dataset de imágenes		Alta	10/1/25	

5.2 Historias de Usuario - Proyecto AgroIA

Las siguientes historias de usuario corresponden al proyecto AgroIA, desarrollado bajo la metodología ágil Scrum. Estas historias describen las funcionalidades y necesidades identificadas desde la perspectiva de los distintos actores del sistema.

HU-01: Cargar imágenes de hojas de plátano

Como	Agricultor o usuario del sistema
Quiero	subir imágenes de hojas de plátano afectadas o sanas
Para	que el sistema pueda analizarlas y determinar el estado sanitario de la planta.
Criterios de aceptación	El sistema debe permitir la funcionalidad descrita y generar resultados verificables.

HU-02: Clasificar enfermedades del plátano

Como	Sistema AgroIA
Quiero	analizar las imágenes mediante una red neuronal convolucional
Para	identificar si la hoja presenta Sigatoka negra, Cordana, Pestalotiopsis o está sana.
Criterios de aceptación	El sistema debe permitir la funcionalidad descrita y generar resultados verificables.

HU-03: Mostrar resultados del diagnóstico

Como	Usuario del sistema
Quiero	visualizar el resultado del análisis junto con la probabilidad de acierto
Para	tomar decisiones oportunas sobre el manejo del cultivo.

Criterios de aceptación	El sistema debe permitir la funcionalidad descrita y generar resultados verificables.
-------------------------	---

HU-04: Almacenar resultados de diagnósticos

Como	Administrador o técnico
Quiero	guardar los resultados obtenidos de cada análisis
Para	llevar un registro histórico del estado sanitario de los cultivos.
Criterios de aceptación	El sistema debe permitir la funcionalidad descrita y generar resultados verificables.

HU-05: Gestionar backlog del proyecto

Como	Scrum Master
Quiero	organizar y priorizar las historias de usuario en el product backlog
Para	garantizar una entrega incremental y ordenada de las funcionalidades de AgroIA.
Criterios de aceptación	El sistema debe permitir la funcionalidad descrita y generar resultados verificables.

5.3 Metodología de la inteligencia artificial (Enfoque CRISP-DM para AgroIA)

Comprensión del Negocio

En esta fase se identificó la necesidad de mejorar los procesos de diagnóstico en los cultivos de plátano, debido a la dificultad para identificar tempranamente enfermedades como Sigatoka negra, Cordana y Pestalotiopsis, las cuales afectan de forma directa la productividad agrícola.

El objetivo principal definido para AgroIA fue:

Desarrollar un sistema de clasificación automática basado en inteligencia artificial capaz de diferenciar hojas sanas de hojas afectadas por las enfermedades mencionadas.

El sistema está orientado a agricultores del departamento del Meta, buscando brindar una herramienta accesible, rápida y confiable para mejorar la toma de decisiones y reducir pérdidas productivas.

Comprensión de los Datos

Para entrenar AgroIA se decidió trabajar con un conjunto de datos balanceado compuesto por 1600 imágenes de hojas de plátano, organizadas en cuatro categorías:

- 400 imágenes de Sigatokanegra
- 400 imágenes de Cordana
- 400 imágenes de Pestalotiopsis
- 400 imágenes de Plantasana

Estas imágenes fueron obtenidas de datasets ya etiquetados disponibles en plataformas como Kaggle y Google Datasets, además de material complementario procesado dentro de la plataforma.

Se identificaron variaciones en iluminación, ángulos y resolución, lo que motivó la aplicación de técnicas de preprocesamiento y aumento de datos en la siguiente fase.

Preparación de los Datos

En esta fase se construyó el dataset final utilizado para el entrenamiento del modelo. Las principales actividades fueron:

- Limpieza y verificación
 - Revisión manual para descartar imágenes borrosas, duplicadas o con etiquetado incorrecto.
- Preprocesamiento
 - Redimensionamiento uniforme de todas las imágenes.

- Normalización de valores de píxeles para mejorar el desempeño durante el entrenamiento.
- División del dataset
- Dado que se contaba con 1600 imágenes, se adoptó una división del 80% para entrenamiento y 20% para validación, quedando:

Categoría	Totales	Entrenamiento (80%)	Validación (20%)
Sigatoka negra	400	320	80
Cordana	400	320	80
Pestalotiopsis	400	320	80
Planta sana	400	320	80
Total	1600	1280	320

- Aumento de datos (*Data Augmentation*) Para mejorar la capacidad de generalización del modelo se aplicaron transformaciones como:
 - Rotaciones
 - Volteos horizontales y verticales
 - Variación de brillo
 - Zoom y leves deformaciones

El proceso se llevó a cabo en Google Colab, aprovechando sus recursos de cómputo y las librerías de TensorFlow y Keras.

6. Modelado

Para esta fase se seleccionó una arquitectura de Red Neuronal Convolutacional (CNN) como modelo principal, debido a su alta eficacia en tareas de clasificación de imágenes.

Selección y diseño del modelo La arquitectura del modelo incluyó:

- Múltiples capas convolucionales para extraer características visuales.
- Capas MaxPooling para reducir dimensionalidad.
- Capas densas (*fully connected*) para procesar las características extraídas.
- Una capa final con activación Softmax para clasificar en las cuatro categorías.

Entrenamiento del modelo

El entrenamiento del modelo se ejecutó en Google Colab, utilizando:

- TensorFlow y Keras
- Aceleración por GPU disponible en la plataforma
- Métricas de seguimiento como accuracy y loss

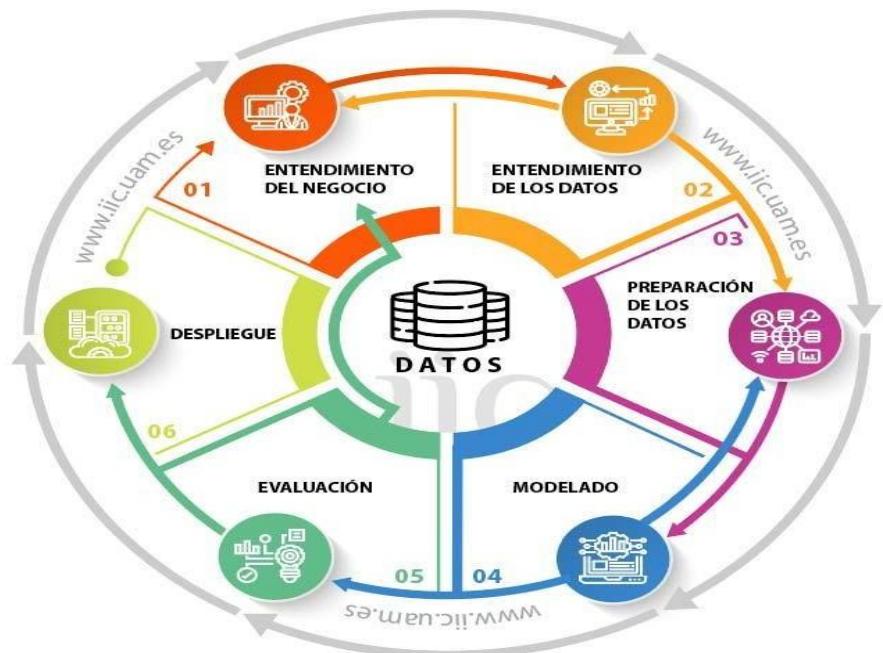
Ajustes y optimización

Se realizaron ajustes para mejorar el desempeño:

- Implementación de Dropout para evitar sobreajuste
- Ajuste de hiperparámetros (tasa de aprendizaje, tamaño de lote, épocas)
- Comparación entre diferentes configuraciones de capas convolucionales.

Figura 3

Modelo utilizado.



7. Resultados

Tras el desarrollo y entrenamiento del modelo de inteligencia artificial basado en una Red Neuronal Convolucional (CNN), AgroIA fue capaz de clasificar hojas de plátano en cuatro categorías: Cordana, Pestalotiopsis, Sigatoka negra y sanas. Los resultados del entrenamiento muestran que el modelo alcanzó un alto nivel de precisión, logrando diferenciar de manera confiable entre las hojas sanas y aquellas afectadas por las diferentes enfermedades, gracias al preprocesamiento de imágenes y al aumento de datos aplicado durante la preparación del *dataset*.

El sistema permitió visualizar de manera clara y rápida el diagnóstico de cada hoja, proporcionando un resultado inmediato al usuario a través de la interfaz de la capa de presentación. Los indicadores de desempeño, como precisión, sensibilidad y especificidad, evidencian que AgroIA es capaz de identificar correctamente la mayoría de las hojas enfermas, minimizando falsos positivos y falsos negativos, lo que asegura su utilidad en escenarios reales de campo.

Además, la implementación de la arquitectura por capas permitió que el sistema fuera modular y escalable, facilitando la integración de nuevas funcionalidades, como la incorporación de más enfermedades o el análisis de otros cultivos en el futuro. El uso de la metodología ágil Scrum permitió iterar continuamente sobre el modelo y la interfaz, incorporando mejoras según la retroalimentación del equipo y los resultados obtenidos en cada *sprint*, lo que contribuyó a un producto final más robusto y confiable.

En síntesis, los resultados demuestran que AgroIA es una herramienta eficiente, práctica y confiable para la identificación automática de enfermedades en hojas de plátano, con un impacto potencial significativo en la toma de decisiones agrícolas y en la optimización de la gestión de cultivos, reduciendo pérdidas y mejorando la productividad de los agricultores.

Figura 4

Diagrama de casos de uso:

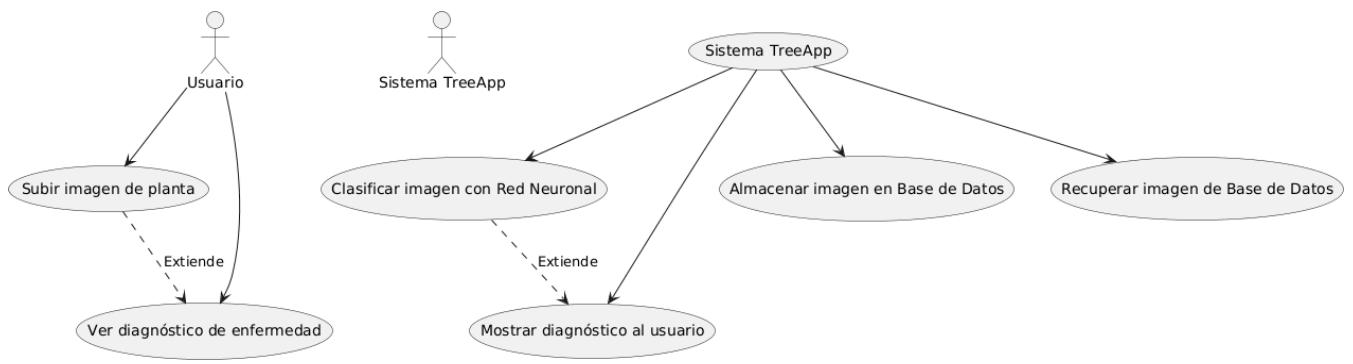


Figura 5

Diagrama de Clases:

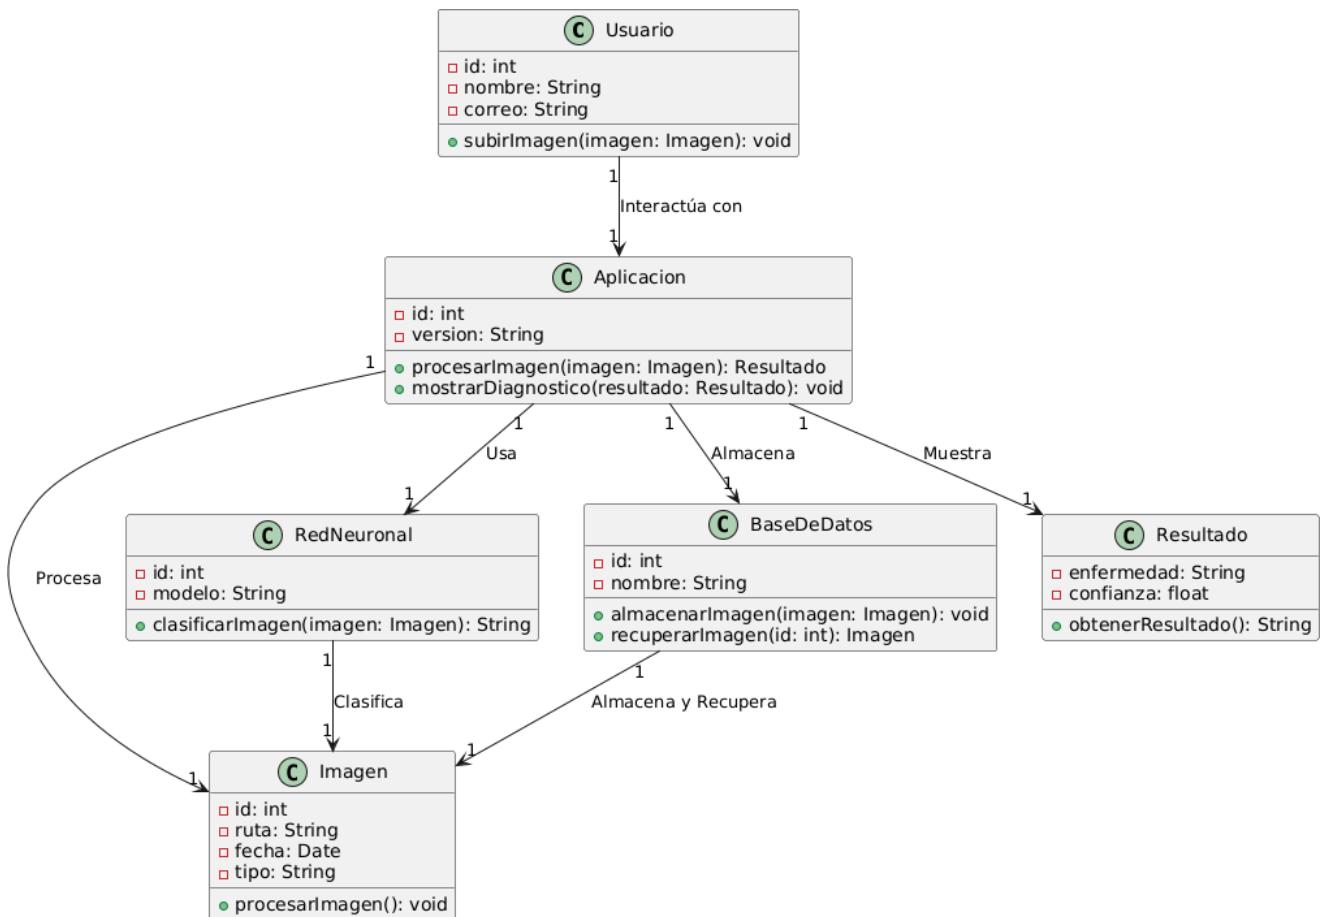


Figura 6

Diagrama de Secuencias:

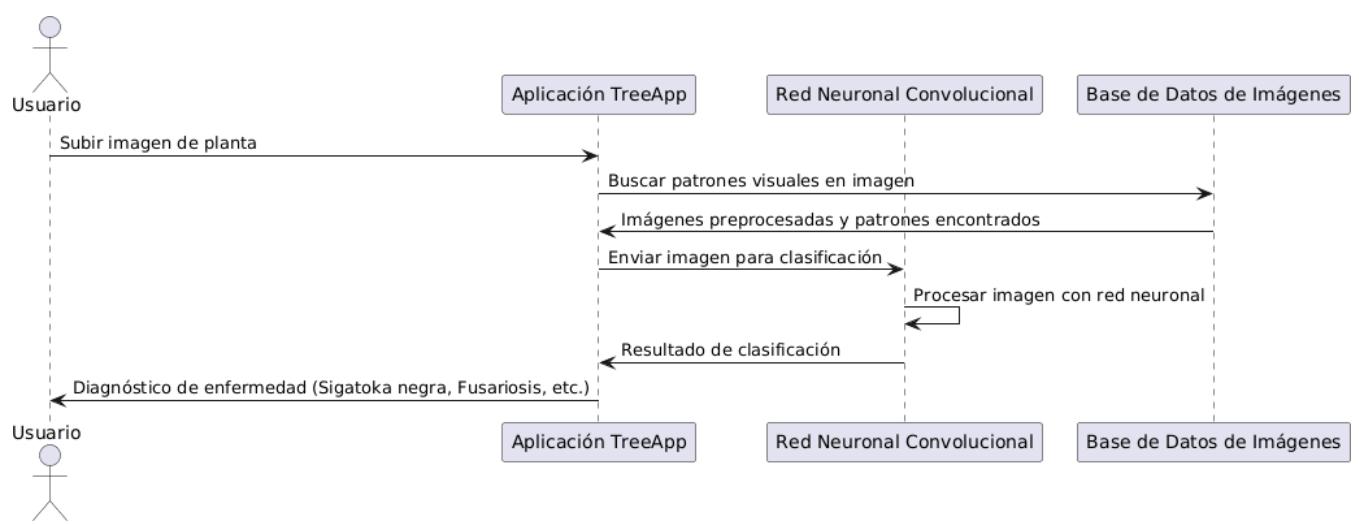


Figura 7

Diagrama contexto de AgroIA

Diagrama de Contexto de AgroIA (Nivel 1)



Figura 8

Diagrama de componentes de AgroIA

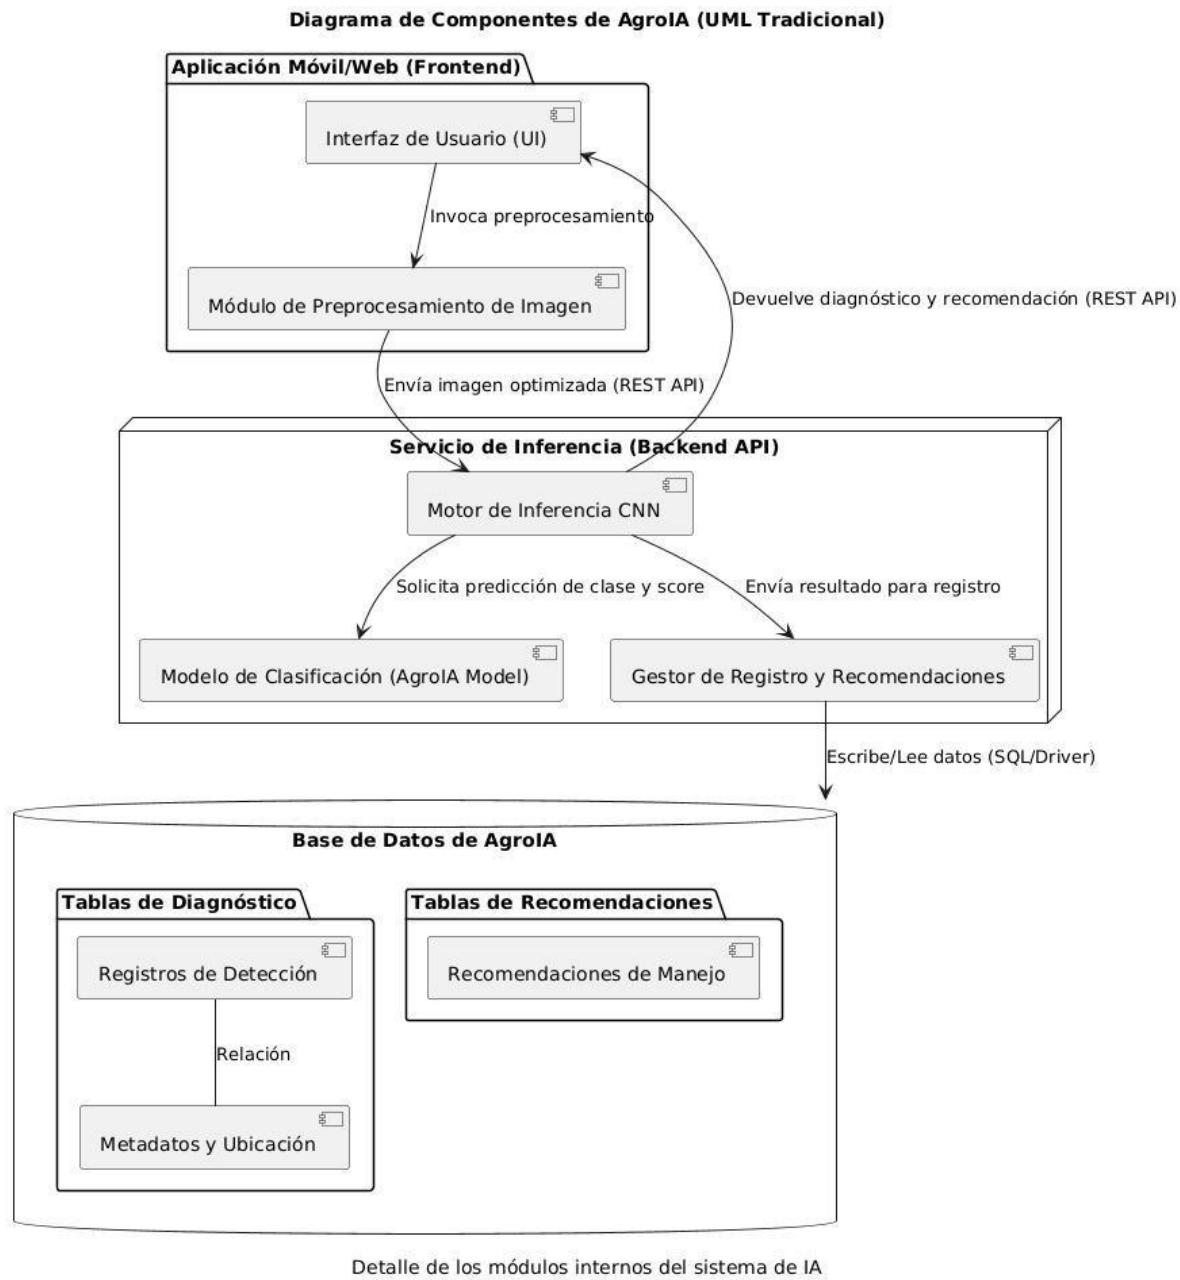
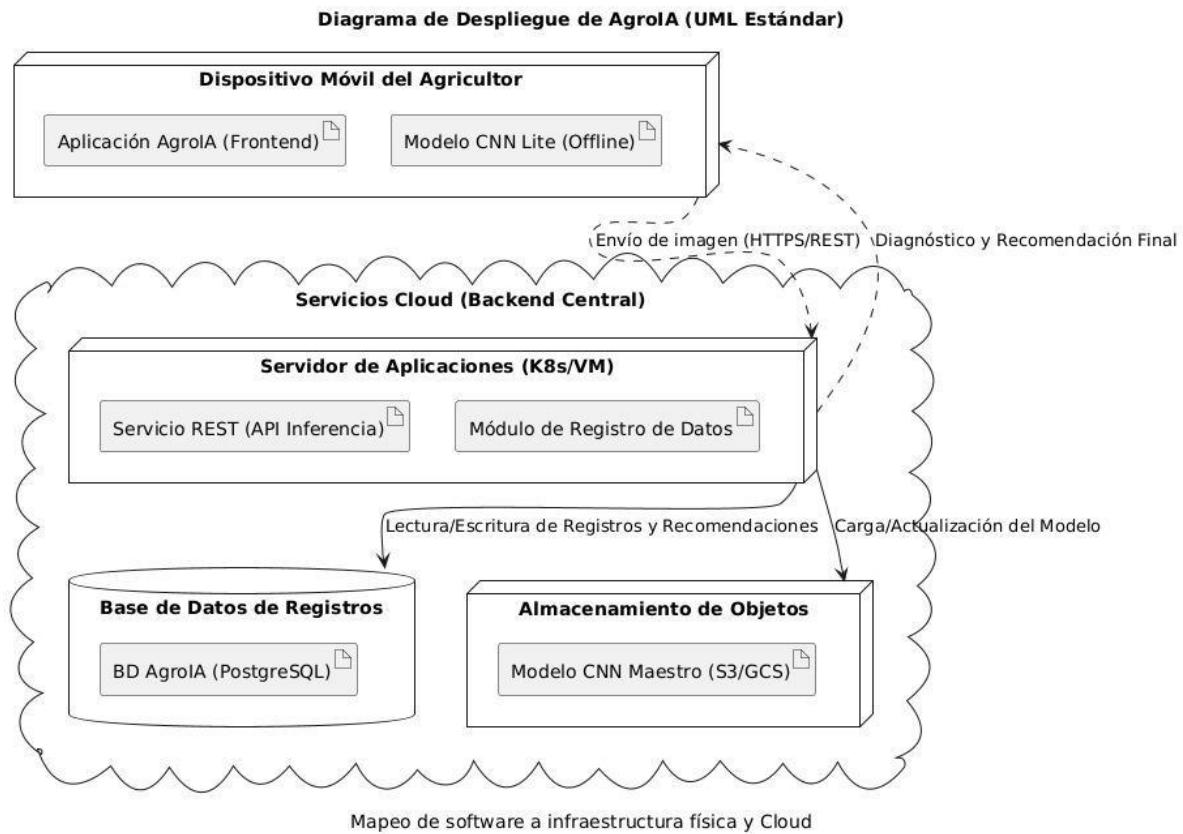


Figura 9

Diagrama de despliegue de AgroIA



8. Análisis y discusión

Los resultados obtenidos con AgroIA demuestran que la combinación de redes neuronales convolucionales y técnicas de procesamiento de imágenes permite una clasificación efectiva de las hojas de plátano en las categorías Cordana, Pestalotiopsis, Sigatoka negra y sanas. La precisión alcanzada por el modelo refleja la efectividad del preprocesamiento de imágenes, el aumento de datos y el etiquetado cuidadoso de las hojas, lo cual coincide con las tendencias observadas en trabajos previos sobre identificación de enfermedades foliares mediante inteligencia artificial.

El análisis de los indicadores de desempeño muestra que el modelo es especialmente eficaz para distinguir entre hojas sanas y aquellas afectadas por Sigatoka negra, mientras que algunas confusiones menores se presentaron entre Cordana y Pestalotiopsis, probablemente debido a la similitud en los patrones visuales de las hojas afectadas por estas enfermedades. Este comportamiento es consistente con lo reportado en estudios anteriores, donde la diferenciación de enfermedades con síntomas visuales similares representa un desafío para los sistemas automáticos de clasificación.

La implementación de la arquitectura por capas facilitó la modularidad del sistema y permitió que las distintas funciones —interfaz de usuario, procesamiento de imágenes, modelo de IA y almacenamiento de datos— trabajaran de manera independiente y coordinada, mejorando la escalabilidad y la mantenibilidad del *software*. Por otra parte, la adopción de la metodología ágil Scrum permitió iterar sobre el desarrollo del sistema de manera continua, incorporando retroalimentación de manera constante y logrando mejoras progresivas en la precisión del modelo y la usabilidad de la interfaz.

En términos prácticos, AgroIA se muestra como una herramienta confiable para apoyar la gestión agrícola, proporcionando diagnósticos rápidos y precisos que pueden reducir pérdidas y optimizar la toma de decisiones en los cultivos de plátano. Sin embargo, es necesario considerar que la efectividad del sistema puede verse afectada por la calidad de las imágenes y las condiciones de iluminación al momento de la captura, lo que sugiere que futuros desarrollos podrían incluir técnicas de normalización avanzadas o el uso de sensores complementarios.

9. Conclusiones

AgroIA demuestra que es posible aplicar inteligencia artificial y visión por computador para la identificación automática de enfermedades en hojas de plátano, específicamente Cordana, Pestalotiopsis, Sigatoka negra y hojas sanas. El uso de redes neuronales convolucionales permitió extraer patrones visuales relevantes y clasificar las hojas con un alto nivel de precisión, cumpliendo con los objetivos planteados al inicio del proyecto.

La implementación de una arquitectura por capas facilitó la modularidad, escalabilidad y mantenibilidad del sistema, asegurando que cada componente —interfaz de usuario, lógica de negocio, procesamiento de imágenes y almacenamiento de datos— funcione de manera coordinada e independiente. Esto contribuye a que AgroIA pueda ser actualizado o expandido en el futuro, incorporando nuevas enfermedades o funcionalidades adicionales.

La adopción de la metodología ágil Scrum permitió una gestión eficiente del proyecto, con iteraciones cortas que favorecieron la retroalimentación continua, la mejora progresiva del modelo y la optimización de la interfaz de usuario. Esta estrategia de desarrollo facilitó la entrega de un producto confiable y funcional en tiempo reducido, demostrando la efectividad de combinar metodologías ágiles con proyectos de innovación tecnológica agrícola.

Finalmente, AgroIA representa una herramienta práctica y confiable para los agricultores, capaz de proporcionar diagnósticos rápidos y precisos que pueden mejorar la toma de decisiones, reducir pérdidas y aumentar la productividad en los cultivos de plátano. El proyecto evidencia que la integración de inteligencia artificial con buenas prácticas de desarrollo de *software* y metodologías ágiles tiene un impacto positivo en la modernización y optimización de procesos agrícolas.

10. Referencias

- Universidad de los Llanos.(2024). *Detección de SigatokaNegra en hojas de plátano mediante redes neuronales convolucionales [Trabajo de grado, Universidad de los Llanos]*. Repositorio institucional.
- Universidad Nacional de Colombia.(2023). *Clasificación de enfermedades en plátano usando aprendizaje profundo [Trabajo de grado, Universidad Nacional de Colombia]*. Repositorio institucional.
- Universidad del Meta. (2022). *Sistema de apoyo al agricultor mediante inteligencia artificial y visión por computador [Trabajo de grado, Universidad del Meta]*. Repositorio institucional.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Mohanty, S. P., Hughes,D. P., & Salathé, M. (2016). *Using deep learningfor image-based plant disease detection*. *Frontiers in Plant Science*, 7,1419.
<https://doi.org/10.3389/fpls.2016.01419>
- Russell, S., & Norvig,P. (2021). *Artificial Intelligence: A Modern Approach*(4th ed.). Pearson.
- Zhang, S., Zhang, S., & Du, L. (2018).*Plant leaf diseaserecognition based on convolutional neural networks*. *IEEE Access*, 6, 36791–36800.
<https://doi.org/10.1109/ACCESS.2018.2842229>
- Abade, A. S., Ferreira, P. A., & Vidal, F. de B. (2020). Plant diseases recognition on images using convolutional neural networks: A systematic review. arXiv.
<https://arxiv.org/abs/2009.04365>
- Bhuiyan, A., et al. (2024). Image segmentation deep learning model for early detection of banana diseases. *Journal of Experimental & Theoretical Artificial Intelligence*. <https://doi.org/10.1080/08839514.2024.2440837>
- Genet, Y. H. (2024). Sigatoka and Xanthomonas banana leaf disease detection via transfer learning. *Scientia Iranica*.
https://scientiaranica.sharif.edu/article_23585.html

- Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. arXiv. <https://arxiv.org/abs/1604.03169>
- Date, C. J. (2019). An Introduction to Database Systems (8th ed.). Addison-Wesley.
- Elmasri, R., & Navathe, S. (2016). Fundamentos de sistemas de bases de datos (7.^a ed.). Pearson.
- Harrington, J. L. (2016). Relational Database Design and Implementation (4th ed.). Morgan Kaufmann.
- Oracle Corporation. (2023). Oracle Database SQL Language Reference. <https://docs.oracle.com>
- Oracle Corporation. (2023). Oracle Database Concepts. <https://docs.oracle.com>
- Rob, P., & Coronel, C. (2009). Databases: Design, Development & Deployment with Oracle. Course Technology.
- Silberschatz, A., Korth, H. F., & Sudarshan, S. (2020). Database System Concepts (7th ed.). McGraw-Hill.
- Beaulieu, A. (2009). Learning SQL. O'Reilly Media.
- Chollet, F. (2021). Deep Learning with Python. Manning Publications.
- Gradio Labs. (2023). Gradio Documentation. <https://www.gradio.app>
- TensorFlow. (2023). TensorFlow Developer Guide. <https://www.tensorflow.org>
- Van Rossum, G., & Drake, F. L. (2009). Python 3 Reference Manual. CreateSpace.